

APRENDIZAJE POR REFUERZO

TAREA 4

DANIEL ROJO MATA
danielrojomata@gmail.com

16 de abril de 2025

CheckList

Los cosos con ✓✓ son los que se han completado.

IMPLEMENTACIÓN

- NSGA-III ✓✓
 - WFG1 ($n = 24, k = 3$) con NSGA-III ✓✓
 - MO-Lunar-Lander (todos los métodos) ✓✓
- Método de descenso ✓✓
 - MO-Lunar-Lander (todos los métodos) ✓✓
- Pareto Q-Learning ✓✓

- *Deep Reinforcement Learning for Multi-Objective Optimization* (2020) ✓✓
- *Multi-Objective Reinforcement Learning with Distributional Preferences* (ICML 2020) ✓✓
- *A Survey of Multiobjective Sequential Decision-Making* (2015) ✓✓
- *MO-PO: Multi-Objective Policy Optimization* (2024) ✓✓

EJERCICIOS & LECTURAS OBSERVACIÓN

- Ejercicios ✓✓

No hice las comparaciones ni los extras.

PROGRAMAS

NSGA 3 (WFG1)

El código se encuentra en el archivo llamado `NSGA3.py`.

Al ejecutar el algoritmo se obtiene la siguiente información:

```
Resumen Estadístico del Frente de Pareto:
Objetivo 1 → Promedio: 1.4093, Desviación Est.: 0.3579
Objetivo 2 → Promedio: 1.9261, Desviación Est.: 0.8016
Objetivo 3 → Promedio: 2.4618, Desviación Est.: 1.1706
```

Además de que se obtiene el siguiente frente de Pareto.




Figura 1: Frente de Pareto para WFG1

Se utilizó el algoritmo **NSGA-III** para resolver el problema **WFG1** con $n_{\text{var}} = 24$ variables de decisión y $n_{\text{obj}} = 3$ objetivos. El algoritmo fue ejecutado con una población de 200 individuos durante 250 iteraciones.

A continuación se presenta un resumen estadístico de los valores obtenidos en el frente de Pareto final (frente no dominado de primer nivel):

Objetivo	Promedio	Desviación Estándar
Objetivo 1	1.4093	0.3579
Objetivo 2	1.9261	0.8016
Objetivo 3	2.4618	1.1706

Observaciones:

- Los valores promedio incrementan progresivamente de Objetivo 1 a Objetivo 3, lo cual se alinea con la forma triangular del frente observado en la visualización tridimensional, 1.
- El Objetivo 3 presenta la mayor dispersión, como se refleja en su desviación estándar, lo que indica una amplia exploración del espacio de soluciones en esa dimensión.

- El frente de Pareto muestra una distribución uniforme de soluciones, con buena cobertura y sin grandes huecos visibles, lo que sugiere una utilización efectiva de los nichos definidos por los puntos de referencia.

A partir de los promedios y desviaciones estándar de los objetivos obtenidos en el frente de Pareto, se pueden hacer las siguientes observaciones:

- Los valores promedio distintos para cada objetivo indican que estos se encuentran en diferentes escalas o presentan distinta dificultad de optimización. Aunque el algoritmo realiza una normalización durante el proceso de selección ambiental, los objetivos con mayor variabilidad pueden influir más en la asignación de nichos y dirección del frente.
- El Objetivo 3 presentó la mayor desviación estándar (1.1706), lo cual sugiere una amplia exploración del espacio en esa dimensión. Esto puede deberse a que el frente tiene una mayor curvatura en esa dirección, o bien a que dicho objetivo impone mayores conflictos con los otros, dificultando la convergencia.
- El Objetivo 1 mostró la menor desviación estándar (0.3579), lo que podría indicar que las soluciones tienden a concentrarse en una región más estrecha del frente. Esto podría reflejar que dicho objetivo es más fácil de optimizar o que impone menos conflictos en comparación con los demás.
- La moderada variabilidad entre los objetivos sugiere un buen equilibrio entre exploración y calidad de soluciones. Esto se refleja en la forma triangular del frente y es coherente con la naturaleza del problema WFG1, caracterizado por trade-offs no lineales.

NSGA 3 (lunar-lander)

El código se encuentra en el archivo llamado `NSGA3_lunar.py`.

Al ejecutar el archivo se obtienen las siguientes figuras.

Frente de Pareto aproximado - MO-Lunar-Lander




Figura 2: Caption




Figura 3: Caption

Se entrenó un agente en el entorno multiobjetivo `mo-lunar-lander-v3`, evaluando su comportamiento a lo largo de 1000 generaciones.

1. Evolución de recompensas por generación

- **Objetivo 1 (azul):** Se mantiene cercano a cero con baja variabilidad. Esto sugiere que el agente logró estabilizar este objetivo tempranamente, o que su influencia en la política actual es limitada.
- **Objetivo 2 (naranja):** Presenta una caída abrupta al inicio, seguida de oscilaciones alrededor de valores muy negativos (~ -4000). Esto podría deberse a penalizaciones acumuladas por uso de combustible u otros costos, y denota una falta de convergencia clara en este objetivo.
- **Objetivo 3 (verde) y Objetivo 4 (rojo):** Ambos son relativamente estables y se mantienen en niveles negativos. El Objetivo 4 muestra menor dispersión, indicando una posible regularidad en comportamientos asociados, como la estabilidad del aterrizaje.

2. Frente de Pareto aproximado

- El frente muestra una distribución dispersa y con escalonamientos. Esto sugiere la presencia de *trade-offs* significativos entre los objetivos, donde mejorar uno implica empeorar otro.
- Todos los valores se ubican en la región negativa del espacio objetivo, lo cual es esperado si los objetivos representan penalizaciones o costos acumulados (como tiempo, energía o inestabilidad).
- La cobertura del frente es razonablemente amplia, lo que indica que el agente exploró diversas políticas con comportamientos diferenciados (e.g., aterrizajes más suaves pero menos eficientes, o viceversa).

El frente de Pareto revela una diversidad aceptable de soluciones, con diferencias claras entre estilos de comportamiento. Sin embargo, los altos valores negativos indican que muchas políticas aún tienen un desempeño subóptimo en al menos uno de los objetivos.

MÉTODO DE DESCENSO

El código se encuentra en el archivo llamado `Descenso.py`.

Al ejecutar el archivo se obtiene lo siguiente:

```
[Episodio 100] → Promedio Retorno Obj.1: -78.78 | Obj.2: -8.14 | Magnitud dirección: 1.891
[Episodio 200] → Promedio Retorno Obj.1: -38.51 | Obj.2: -5.39 | Magnitud dirección: 1.856
[Episodio 300] → Promedio Retorno Obj.1: -158.87 | Obj.2: -8.30 | Magnitud dirección: 1.947
[Episodio 400] → Promedio Retorno Obj.1: -117.34 | Obj.2: -6.76 | Magnitud dirección: 1.931
[Episodio 500] → Promedio Retorno Obj.1: -104.97 | Obj.2: -7.21 | Magnitud dirección: 1.788
.
.
.
```

Durante el entrenamiento se ejecutaron un total de 5000 episodios. Para evitar la saturación visual en la salida por pantalla, los resultados se imprimieron únicamente cada 100 episodios.

Al finalizar el entrenamiento se reportan las siguientes estadísticas:

Estadísticas de la recompensa total por episodio:

	Objetivo	Promedio	Desviación Estándar
0	Objetivo 1	-140.801971	59.836609
1	Objetivo 2	-3.037191	6.661281

Además se obtiene la siguiente figura:




Figura 4: Recompensas obtenidas

A continuación, se muestra un resumen de las estadísticas obtenidas al finalizar el entrenamiento:

Objetivo	Promedio	Desviación Estándar
Objetivo 1 (recompensa del entorno)	-140.80	59.84
Objetivo 2 (penalización por motor)	-3.04	6.66

Cuadro 1: Estadísticas de recompensa total acumulada por episodio

- La recompensa promedio en el Objetivo 1 es de aproximadamente -140 , lo cual indica que el agente no logró aprender una política efectiva para resolver el entorno. Un agente exitoso en **LunarLander-v3** típicamente alcanza valores promedio superiores a $+100$.
- El Objetivo 2 presenta una penalización baja (cercana a 0), lo que sugiere que el agente evitó el uso excesivo de los motores. Sin embargo, esto puede deberse a que simplemente eligió no actuar (acción 0), lo cual no siempre implica un comportamiento deseado.

En la Figura 4 se observa la evolución de la recompensa por episodio. La línea correspondiente al Objetivo 1 muestra una gran variabilidad y tendencia negativa, mientras que el Objetivo 2 permanece relativamente estable en valores bajos.

- La dirección de actualización calculada con el método de Lara podría favorecer en exceso el segundo objetivo (menor uso de motores), lo cual limita el aprendizaje de una política efectiva.
- La falta de ponderación entre objetivos hace que se combinen por igual, a pesar de que en este entorno uno tiene mayor prioridad que el otro.
- Existe la posibilidad de que el agente se haya mantenido inactivo (acción 0) para evitar penalizaciones, sin ejecutar una política activa de aterrizaje.

Pareto Q-Learning

El código se encuentra en el archivo **ParetoQLearning.py**.

Al ejecutar el archivo se obtiene lo siguiente:

```
=====
Episodio 0
Objetivo      Valor
Obj 1         -100.0
Obj 2         -75.42
Obj 3         -26.0
Obj 4         -47.0
=====
Episodio 50
Objetivo      Valor
Obj 1         -100.0
Obj 2          -1.0
Obj 3         -28.0
Obj 4         -48.0
=====
.
```




Figura 5: Frontera de Pareto aproximada obtenida con Pareto Q-Learning.




Figura 6: Evolución de las recompensas por episodio durante el entrenamiento.

A partir de los resultados obtenidos, se observa que el agente mantiene una política constante respecto al Objetivo 1, con valores cercanos a -100 a lo largo del entrenamiento. En cambio, el comportamiento del Objetivo 2 muestra una alta variabilidad, indicando que el agente explora distintas estrategias que afectan este objetivo de forma significativa.

La forma vertical de la frontera de Pareto en la Figura 5 sugiere que las soluciones encontradas por el algoritmo difieren principalmente en el segundo objetivo, mientras que el primero permanece sin mejoras sustanciales. Esto puede ser indicio de que el entorno impone una fuerte penalización al intentar mejorar ambos objetivos simultáneamente, o bien que el agente no ha explorado suficientemente el espacio de políticas.

Finalmente, se recomienda incrementar el número de episodios y la tasa de exploración inicial para obtener una mayor diversidad de soluciones, así como guardar las políticas asociadas a cada punto no dominado para realizar un análisis más profundo del comportamiento estratégico del agente.

EJERCICIOS

1. Ejercicios

1. Considere el problema

$$\min_{x \in [-1, 1]} \left(\sqrt{5 - x^2}, \frac{x}{2} \right)$$


- Dibuje el espacio de decisión y de objetivos.

Solución.

El **espacio de decisión** está dado por el intervalo $x \in [-1, 1]$, lo que significa que las posibles soluciones al problema se restringen únicamente a ese rango de valores para la variable x .

A partir de este conjunto de decisiones, se construye el **espacio de objetivos** al evaluar cada valor de x en las funciones objetivo $f_1(x) = \sqrt{5 - x^2}$ y $f_2(x) = \frac{x}{2}$. Este procedimiento genera una colección de puntos $(f_1(x), f_2(x))$ que representan cómo se comportan simultáneamente ambas funciones dentro del rango permitido.

En este espacio, cada punto corresponde a una solución x transformada mediante las funciones f_1 y f_2 . En la gráfica resultante, el eje horizontal representa los valores de $f_1(x)$ y el eje vertical los de $f_2(x)$.



- Describa el conjunto de soluciones eficientes.


Solución.

Dado que en este caso se busca minimizar ambos objetivos, la única solución no dominada es aquella que se encuentra en el extremo inferior izquierdo del espacio de objetivos, la cual ha sido marcada con una **x** en la imagen.

Esta solución se considera **no dominada** porque no existe otra dentro del conjunto de soluciones factibles que sea mejor en al menos uno de los objetivos sin empeorar el otro. Es decir,

cualquier intento por mejorar el valor de una función objetivo llevaría inevitablemente a un deterioro en la otra.

Este tipo de soluciones forman lo que se conoce como el *frente de Pareto*, y en este caso particular, dicho frente se reduce a un único punto eficiente desde el punto de vista multiobjetivo.



2. Considere el siguiente problema

$$\min_{x \in [-10, 10]^2} (x_1^2 + x_2^2, (x_1 - 5)^2 + (x_2 - 5)^2)$$

- Utilizar el método de suma ponderada con $w = [0.5, 0.5]^T$ y encontrar el óptimo.

Solución.

A partir de las funciones objetivo originales se construye una función escalar compuesta mediante una combinación lineal ponderada:

$$f(x) = w_1 f_1(x) + w_2 f_2(x)$$

Al sustituir los valores proporcionados para los pesos, se obtiene lo siguiente:

$$\begin{aligned} f(x) &= 0.5(x_1^2 + x_2^2) + 0.5[(x_1 - 5)^2 + (x_2 - 5)^2] \\ &= 0.5(x_1^2 + x_2^2) + 0.5[x_1^2 - 10x_1 + 25 + x_2^2 - 10x_2 + 25] \\ &= 0.5x_1^2 + 0.5x_2^2 + 0.5x_1^2 - 5x_1 + 12.5 + 0.5x_2^2 - 5x_2 + 12.5 \\ &= x_1^2 + x_2^2 - 5x_1 - 5x_2 + 25 \end{aligned}$$

La función resultante es cuadrática y convexa, por lo tanto, su mínimo local coincide con el mínimo global. Para encontrar dicho punto óptimo, se calculan las derivadas parciales respecto a cada variable e igualan a cero:

$$\frac{\partial f}{\partial x_1} = 2x_1 - 5 = 0 \quad \Rightarrow \quad x_1 = \frac{5}{2}$$

$$\frac{\partial f}{\partial x_2} = 2x_2 - 5 = 0 \quad \Rightarrow \quad x_2 = \frac{5}{2}$$

Finalmente, al evaluar la función f_1 en este punto óptimo $x^* = (\frac{5}{2}, \frac{5}{2})$ se obtiene:

$$f_1(x^*) = \left(\frac{5}{2}\right)^2 + \left(\frac{5}{2}\right)^2 = \frac{25}{4} + \frac{25}{4} = \frac{50}{4} = 12.5$$

$$f_2(x^*) = \left(\frac{5}{2} - 5\right)^2 + \left(\frac{5}{2} - 5\right)^2 = \left(-\frac{5}{2}\right)^2 + \left(-\frac{5}{2}\right)^2 = \frac{25}{4} + \frac{25}{4} = 12.5$$

Por lo tanto, el valor del vector objetivo en el punto óptimo es:

$$(f_1(x^*), f_2(x^*)) = (12.5, 12.5)$$

- A partir del punto calculado en el inciso anterior, se procede a realizar un paso utilizando el método de continuación del *directed search*.

Solución.

El método de continuación basado en búsqueda dirigida consiste en alterar ligeramente el vector de pesos w y resolver nuevamente el problema escalar. Esta estrategia permite explorar distintas regiones de la frontera de Pareto, generando así nuevos puntos eficientes en direcciones cercanas al punto actual.

Para ello, se escoge un nuevo vector de pesos definido como:

$$w^{(1)} = \begin{bmatrix} 0.5 + \epsilon \\ 0.5 - \epsilon \end{bmatrix}, \quad \text{donde } \epsilon > 0$$

En este caso, al considerar $\epsilon = 0.05$, se tiene:

$$w^{(1)} = \begin{bmatrix} 0.55 \\ 0.45 \end{bmatrix}$$

Este nuevo vector da lugar al siguiente problema de minimización ponderada:

$$\min_{x \in [-10, 10]^2} (0.55f_1(x) + 0.45f_2(x))$$

Reemplazando las expresiones de f_1 y f_2 se obtiene:

$$\begin{aligned} f^{(1)}(x) &= 0.55(x_1^2 + x_2^2) + 0.45[(x_1 - 5)^2 + (x_2 - 5)^2] \\ &= 0.55(x_1^2 + x_2^2) + 0.45(x_1^2 - 10x_1 + 25 + x_2^2 - 10x_2 + 25) \\ &= (0.55 + 0.45)x_1^2 + (0.55 + 0.45)x_2^2 - 4.5x_1 - 4.5x_2 + 22.5 \\ &= x_1^2 + x_2^2 - 4.5x_1 - 4.5x_2 + 22.5 \end{aligned}$$

Para encontrar el mínimo de esta nueva función, se derivan parcialmente con respecto a cada variable e igualan a cero:

$$\begin{aligned} \frac{\partial f^{(1)}}{\partial x_1} &= 2x_1 - 4.5 = 0 \quad \Rightarrow \quad x_1 = \frac{9}{4} \\ \frac{\partial f^{(1)}}{\partial x_2} &= 2x_2 - 4.5 = 0 \quad \Rightarrow \quad x_2 = \frac{9}{4} \end{aligned}$$

De este modo, el nuevo punto óptimo encontrado es:

$$x^* = \left(\frac{9}{4}, \frac{9}{4}\right)$$

Evaluando las funciones objetivo en este punto:

$$f_1(x^*) = \left(\frac{9}{4}\right)^2 + \left(\frac{9}{4}\right)^2 = 2 \cdot \frac{81}{16} = \frac{162}{16} = 10.125$$

$$f_2(x^*) = \left(\frac{9}{4} - 5\right)^2 + \left(\frac{9}{4} - 5\right)^2 = 2 \cdot \left(-\frac{11}{4}\right)^2 = 2 \cdot \frac{121}{16} = \frac{242}{16} = 15.125$$

En consecuencia, el nuevo punto generado mediante este paso de continuación es:

$$x^* = \left(\frac{9}{4}, \frac{9}{4}\right), \quad \text{con valores en el espacio de objetivos } (f_1(x^*), f_2(x^*)) = (10.125, 15.125)$$

- Dados los siguientes vectores en el espacio de los objetivos: $a = [0, 1]$, $b = [0.4, 0.6]$, $c = [0.5, 0.5]$, $d = [1, 0]$, se pide calcular la *crowding distance* de cada uno.

Solución.

La *crowding distance* se calcula objetivo por objetivo. En cada caso, los vectores son ordenados con base en los valores del objetivo correspondiente, y se asigna una distancia infinita a los extremos (mínimo y máximo), ya que son automáticamente preservados por su valor extremo. A los elementos intermedios se les asigna una distancia normalizada con respecto al rango del objetivo.

a) **Para el objetivo f_1 :**

$$\text{Orden: } a = 0, \quad b = 0.4, \quad c = 0.5, \quad d = 1$$

$$f_1^{\min} = 0, \quad f_1^{\max} = 1$$

Aplicando la fórmula para los puntos intermedios:

$$CD_a^{(1)} = \infty \quad (\text{frontera})$$

$$CD_b^{(1)} = \frac{f_1(c) - f_1(a)}{f_1^{\max} - f_1^{\min}} = \frac{0.5 - 0}{1 - 0} = 0.5$$

$$CD_c^{(1)} = \frac{f_1(d) - f_1(b)}{f_1^{\max} - f_1^{\min}} = \frac{1 - 0.4}{1} = 0.6$$

$$CD_d^{(1)} = \infty \quad (\text{frontera})$$

b) **Para el objetivo f_2 :**

$$\text{Orden: } d = 0, \quad c = 0.5, \quad b = 0.6, \quad a = 1$$

$$f_2^{\min} = 0, \quad f_2^{\max} = 1$$

Asignando las distancias normalizadas:

$$CD_d^{(2)} = \infty \quad (\text{frontera})$$

$$CD_c^{(2)} = \frac{f_2(b) - f_2(d)}{f_2^{\max} - f_2^{\min}} = \frac{0.6 - 0}{1} = 0.6$$

$$CD_b^{(2)} = \frac{f_2(a) - f_2(c)}{f_2^{\max} - f_2^{\min}} = \frac{1 - 0.5}{1} = 0.5$$

$$CD_a^{(2)} = \infty \quad (\text{frontera})$$

Sumando las contribuciones de ambos objetivos, se obtiene la distancia total para cada vector:

$$CD_a = \infty$$

$$CD_b = 0.5 + 0.5 = 1.0$$

$$CD_c = 0.6 + 0.6 = 1.2$$

$$CD_d = \infty$$

- Calcular la aptitud de los vectores utilizando la función de escalarización de Tchebycheff, con los pesos dados por la matriz:

$$W = \begin{bmatrix} 0 & 1 \\ 0.5 & 0.5 \\ 1 & 0 \end{bmatrix}$$

Solución.

La escalarización de Tchebycheff permite convertir un problema multiobjetivo en uno escalar, facilitando la comparación entre soluciones. Esta técnica se basa en la siguiente fórmula:

$$T_w(x) = \max_i (w_i \cdot |x_i - z_i|)$$

donde w representa el vector de pesos y z es el *punto ideal*, definido como el mínimo valor alcanzado por cada función objetivo. Para los vectores considerados, el punto ideal es:

$$z = (\min f_1, \min f_2) = (0, 0)$$

Dado esto, la fórmula se simplifica a:

$$T_w(x) = \max_i (w_i \cdot x_i)$$

A continuación se evalúan las aptitudes de los vectores a , b , c y d usando cada uno de los vectores de pesos:

- **Para** $a = [0, 1]$:

$$T_{[0, 1]}(a) = \max(0 \cdot 0, 1 \cdot 1) = 1$$

$$T_{[0.5, 0.5]}(a) = \max(0.5 \cdot 0, 0.5 \cdot 1) = 0.5$$

$$T_{[1, 0]}(a) = \max(1 \cdot 0, 0 \cdot 1) = 0$$

- **Para** $b = [0.4, 0.6]$:

$$T_{[0, 1]}(b) = \max(0 \cdot 0.4, 1 \cdot 0.6) = 0.6$$

$$T_{[0.5, 0.5]}(b) = \max(0.5 \cdot 0.4, 0.5 \cdot 0.6) = \max(0.2, 0.3) = 0.3$$

$$T_{[1, 0]}(b) = \max(1 \cdot 0.4, 0 \cdot 0.6) = 0.4$$

- **Para** $c = [0.5, 0.5]$:

$$T_{[0, 1]}(c) = \max(0 \cdot 0.5, 1 \cdot 0.5) = 0.5$$

$$T_{[0.5, 0.5]}(c) = \max(0.5 \cdot 0.5, 0.5 \cdot 0.5) = \max(0.25, 0.25) = 0.25$$

$$T_{[1, 0]}(c) = \max(1 \cdot 0.5, 0 \cdot 0.5) = 0.5$$

- **Para** $d = [1, 0]$:

$$T_{[0, 1]}(d) = \max(0 \cdot 1, 1 \cdot 0) = 0$$

$$T_{[0.5, 0.5]}(d) = \max(0.5 \cdot 1, 0.5 \cdot 0) = \max(0.5, 0) = 0.5$$

$$T_{[1, 0]}(d) = \max(1 \cdot 1, 0 \cdot 0) = 1$$

- Calcular la contribución al hipervolumen de cada vector con el punto de referencia $[5, 5]^T$

Solución.

El hipervolumen en el contexto de minimización se define como el área dominada por un conjunto de soluciones no dominadas, acotada por un punto de referencia.

Para un punto $p = [p_1, p_2]$, la contribución individual al hipervolumen se puede calcular como:

$$HV(p) = (r_1 - p_1)(r_2 - p_2)$$

Con $r = [5, 5]$, calculamos:

- Para $a = [0, 1]$:

$$HV(a) = (5 - 0)(5 - 1) = 5 \cdot 4 = 20$$

- Para $b = [0.4, 0.6]$:

$$HV(b) = (5 - 0.4)(5 - 0.6) = 4.6 \cdot 4.4 = 20.24$$

- Para $c = [0.5, 0.5]$:

$$HV(c) = (5 - 0.5)(5 - 0.5) = 4.5 \cdot 4.5 = 20.25$$

- Para $d = [1, 0]$:

$$HV(d) = (5 - 1)(5 - 0) = 4 \cdot 5 = 20$$

Por lo tanto, las contribuciones individuales al hipervolumen son:

$$HV(a) = 20$$

$$HV(b) = 20.24$$

$$HV(c) = 20.25$$

$$HV(d) = 20$$

LECTURAS

LECTURA 1: A multi-objective deep reinforcement learning framework

El artículo propone una arquitectura versátil y escalable para abordar problemas de aprendizaje por refuerzo profundo con múltiples objetivos (MODRL).

El eje central del texto gira en torno a la creación de una plataforma modular en Python que integre estrategias de política única y múltiple, y que permita la aplicación de algoritmos de aprendizaje profundo como DQN en contextos multiobjetivo.

Desde el inicio, los autores exponen una limitación clara del estado del arte: la mayoría de los marcos anteriores se centran en tareas simples de tipo gridworld y no soportan entradas visuales ni el uso directo de redes neuronales profundas. La propuesta busca superar estas limitaciones mediante una separación clara entre componentes (red neuronal, algoritmo DRL, entorno) y un sistema de configuración adaptable. Gracias a esta estructura, el marco permite no solo la integración de distintas variantes de DQN, sino también la adaptación a distintos tipos de entrada, como vectores o imágenes.

Para demostrar la eficacia de su framework, se presentan experimentos en dos entornos clásicos: Deep Sea Treasure (DST) y Mountain Car, ambos en versiones con múltiples objetivos. En el caso de DST, se exploran las limitaciones del enfoque lineal para hallar soluciones en frentes de Pareto con curvatura, mostrando cómo el método no lineal TLO (Thresholded Lexicographic Ordering) logra capturar soluciones que el método lineal ignora. Para el entorno Mountain Car, el enfoque lineal mostró ser más eficaz, lo cual lleva a una observación importante: la idoneidad del método (lineal vs no lineal) depende de la naturaleza de las recompensas (intrínsecas vs extrínsecas).

El artículo destaca por su claridad metodológica y por ofrecer una evaluación robusta mediante la métrica de hipervolumen, que permite comparar el rendimiento de distintos enfoques sin necesidad de conocer el frente óptimo. En cuanto a fortalezas, resalta la propuesta de multithreading para acelerar el entrenamiento paralelo de políticas, lo cual es particularmente útil en el caso multi-policy. Como debilidad, puede señalarse que el método TLO, aunque eficaz en ciertos casos, requiere un ajuste manual de umbrales y no generaliza bien cuando hay múltiples recompensas intrínsecas, como se evidenció en el entorno Mountain Car.

Comparado con otros trabajos como los de Mossalam (2016) o Tajmajer (2017), que también extendieron DQN al entorno multiobjetivo, este artículo destaca por ofrecer una herramienta más abierta, flexible y adaptable, y no limitarse a una arquitectura específica o a un problema. La propuesta busca sentar las bases para un estándar de desarrollo en el campo MODRL, al estilo de lo que RLlib representa para RL tradicional.

En cuanto a su impacto, el marco presentado tiene un gran potencial en aplicaciones reales donde los objetivos son naturalmente múltiples y conflictivos, como el control de vehículos autónomos, la programación energética o la manufactura inteligente.

En mi caso, el texto resultó interesante por su enfoque modular y su claridad para explicar cómo una buena arquitectura de software puede facilitar la investigación y experimentación en un área compleja como el aprendizaje por refuerzo multiobjetivo.

LECTURA 2: Multi-Objective Proximal Policy Optimization for Digital Twin-Assisted Computing Offloading in Internet of Vehicles

El artículo presenta una propuesta que une dos áreas de la computación moderna: los gemelos digitales (DT) y el aprendizaje por refuerzo profundo multiobjetivo, con aplicación directa en el contexto del Internet de los Vehículos (IoV). Su objetivo central es minimizar el costo total de la descarga de tareas computacionales mediante un enfoque que equilibre tres factores: latencia, consumo energético y costo de computación en la nube.

La idea central del trabajo se sostiene al combinar información proveniente de los gemelos digitales con algoritmos como PPO y MOEA/D; es posible tomar decisiones óptimas de descarga de tareas en tiempo real, incluso en entornos vehiculares altamente dinámicos y con incertidumbre. El artículo desarrolla esta idea a través de un marco matemático robusto, simulaciones detalladas y comparaciones con otros métodos.

Entre los principales aciertos está la clara estructuración del problema como una optimización multiobjetivo y su modelado como un proceso de decisión de Markov (MDP). También destaca la forma en que el agente, entrenado con MOEA/D-PPO, es capaz de generar estrategias que logran un balance entre varios objetivos. Las simulaciones muestran resultados contundentes: mejor velocidad de convergencia, mayor estabilidad, y soluciones más cercanas al frente de Pareto, especialmente al comparar con soluciones sin gemelos digitales o con enfoques de un solo objetivo.

En cuanto al estilo del artículo, se percibe un enfoque técnico, con explicaciones claras de los modelos y decisiones de diseño algorítmico. No obstante, una posible debilidad radica en que la evaluación experimental, aunque suficiente, podría enriquecerse con entornos más variados, así como con pruebas en escenarios reales, dado que el impacto de la desviación entre el DT y el entorno físico es central en su propuesta.

Comparado con estudios previos que utilizaban solo los datos en bruto, este artículo aporta un avance al incorporar la desviación del DT y utilizarla como una variable explícita en el cálculo de costos, lo que lo vuelve más realista y adaptable.

El impacto del texto puede guiar nuevas investigaciones en la intersección de RL y DT, y también inspirar aplicaciones prácticas en sistemas vehiculares, ciudades inteligentes o logística distribuida.

LECTURA 3: Prediction-Guided Multi-Objective Reinforcement Learning for Continuous Robot Control

El artículo se inserta en un contexto de creciente interés por resolver problemas de control robótico que involucran múltiples objetivos conflictivos, como balancear velocidad y eficiencia energética en robots con movimiento continuo. Su propuesta consiste en un algoritmo de aprendizaje evolutivo guiado por predicciones que no solo encuentra políticas óptimas individuales, sino que construye una representación continua del frente de Pareto a través de interpolaciones de familias de políticas distintas.

La idea central de los autores es que una representación efectiva de soluciones en escenarios multiobjetivo no puede lograrse con una sola familia de políticas, sino que requiere de múltiples familias disjuntas en el espacio de parámetros.

Para desarrollar esta idea, el texto se apoya en tres pilares: un algoritmo basado en gradiente de políticas multiobjetivo, un modelo predictivo que anticipa mejoras por dirección de optimización, y un análisis posterior para reconstruir el frente de Pareto. Además, los autores diseñan un benchmark robusto con entornos de control robótico continuo, lo cual refuerza la aplicabilidad y validez experimental de su enfoque.

Entre las fortalezas del artículo destacan su claridad estructural, la solidez empírica del enfoque propuesto, demostrada con mejoras notables en métricas como hipervolumen y dispersión frente a otros métodos, y su capacidad para extenderse a entornos con tres objetivos. Por otra parte, la debilidad principal radica en su dificultad para capturar zonas del frente de Pareto donde se presentan mínimos locales persistentes, algo que el modelo predictivo actual no logra anticipar. Asimismo, aunque la interpolación entre políticas dentro de una familia resulta eficaz, esta técnica podría ser sensible en aplicaciones con topologías más complejas del espacio de políticas.

Este trabajo se relaciona con otras propuestas dentro del aprendizaje por refuerzo multiobjetivo (MORL), especialmente las que emplean políticas meta o aproximaciones por descomposición como MOEA/D. Sin embargo, se diferencia al integrar modelos de predicción de mejora que dirigen la exploración hacia áreas más prometedoras del frente de Pareto, lo cual representa un avance notable sobre enfoques que distribuyen tareas de forma aleatoria o ciega. Frente a métodos como META, que buscan una sola política adaptable, este artículo demuestra que una representación por múltiples familias ofrece un mejor compromiso entre generalización y desempeño óptimo.

El texto establece una nueva metodología para abordar problemas de control realistas con objetivos múltiples, lo cual puede ser importante en robótica aplicada, simulaciones físicas o diseño automatizado. Por otro lado, contribuye a llenar un vacío en benchmarks para MORL en espacios de acción continua, proporcionando una plataforma replicable para evaluación futura.

LECTURA 4: Why Multi-objective Reinforcement Learning?

El artículo parte de una observación: en el campo del aprendizaje por refuerzo (RL), los métodos que consideran múltiples objetivos siguen siendo una rareza, a pesar de que muchos problemas reales implican metas que compiten entre sí. La idea central es clara: aunque el resultado final de una política pueda medirse como una utilidad escalar, no siempre es viable, deseable o posible reducir el problema a una sola dimensión en las etapas en las que el agente debe aprender.

A lo largo del texto, los autores desarrollan tres escenarios clave que ilustran esta necesidad. En el primero, los pesos que definen la importancia relativa de cada objetivo son desconocidos durante el entrenamiento; en el segundo, el proceso de toma de decisiones debe asistir al usuario sin imponer una combinación numérica de preferencias; y en el tercero, aunque se conocen los pesos y la forma de escalar los objetivos, el problema se complica porque la solución óptima podría no ser determinista o estacionaria. Estos escenarios refuerzan el argumento de que la simplificación a un único objetivo puede perder matices importantes.

Un punto fuerte del artículo es su insistencia en un enfoque basado en la utilidad real del usuario, en lugar de seguir la idea de que siempre hay que construir todo el frente de Pareto. Esto le da al texto un carácter práctico y flexible, que reconoce que, en la mayoría de los casos, no necesitamos todas las soluciones posibles, sino únicamente aquellas que sean útiles bajo las condiciones del problema. En vez de una solución universal, proponen adaptar el algoritmo a la naturaleza de la función de utilidad, los tipos de políticas permitidas y las restricciones del entorno.

Entre las fortalezas del texto destacan la claridad en los ejemplos, la relevancia de los escenarios planteados y la propuesta concreta de un cambio de paradigma. Como debilidad, podría señalarse que el artículo asume cierta familiaridad con conceptos técnicos, lo que podría limitar su accesibilidad a audiencias menos especializadas.

El texto se inserta de manera directa en un debate actual del aprendizaje por refuerzo. Mientras autores como Sutton han defendido que toda meta puede representarse como una suma escalar de recompensas, Roijers y colaboradores cuestionan esa premisa al mostrar cómo, en la práctica, esa conversión puede ser no trivial, o incluso contraproducente. Su comparación con el enfoque tradicional ayuda a destacar el valor añadido del marco multiobjetivo, especialmente cuando se toma en cuenta la perspectiva del usuario final.

No solo desafía un supuesto clásico del campo, sino que ofrece una guía concreta para adaptar los algoritmos a las verdaderas necesidades del entorno. Esto podría influir tanto en la investigación como en aplicaciones reales donde la flexibilidad y personalización son factores esenciales.

A nivel personal, me pareció especialmente valioso el enfoque de "no todo es Pareto", que invita a pensar de forma más estratégica sobre qué soluciones vale la pena buscar.